天序明衡

TEMISGUARD

让每一次运行都有据可查

基于 openjiuwen 的智能体行动可信层

项	内容
文档名称	天序明衡 TemisGuard 产品需求文档
版本	v2.7
适用范围	产品整体：决策采集、证据记录、不确定性标记与债务、实时控制、账本、读数、发布闸、整改报价、版本对比
关联文档	《关键决策白名单 v1.0》、《PROGRESS》
载体与依赖	openJiuwen 0.1.20.post1；OpenTelemetry

1 背景与问题

1.1 业务背景

智能体已从问答型应用进入生产系统，开始执行写库、发信、下单、调用外部接口等具有副作用的动作。这类动作一旦执行，损失发生在运行时，无法通过事后评测或发布评审挽回。当前主流的可观测方案记录对话内容与调用耗时，能够回答"系统说了什么、耗时多少"，但无法回答"该动作是否应当放行、放行依据是什么、事后能否被第三方复算"。

1.2 现状问题

编号	问题	具体表现	业务影响
P1	决策过程不可见	一次工具调用只留下请求与响应，缺少判定依据、参数摘要与责任主体	故障定位依赖人工复现
P2	执行前无控制点	异常动作在执行后才被发现，只能事后补偿	损失不可逆
P3	证据不可复算	证据散落在日志中，模型与参数未固化，换人或换环境无法重算	审计结论无法采信
P4	责任无法归属	缺少"谁批准、依据什么"的记录	无法追责、无法投保、无法通过外部审查

1.3 不解决的后果

Agent 的生产使用将长期停留在低风险场景：涉及资金、数据导出、外部通信的动作必须保留人工全程接管，智能体的效率收益无法兑现；同时，出现事故时组织无法提供可核验材料，责任界定停留在口头说明。

2 产品定位与范围

2.1 定位

本产品提供两项核心能力，作用于智能体的执行过程。

Agent 行为可审计：每一次关键决策在执行前写入意图记录，执行后追加结果记录；两条记录以内容指纹首尾相连，只可追加、不可修改；账本自包含，不依赖链路日志，第三方可独立复算。它回答四个问题：做了什么、依

据是什么、结果是什么、有没有被改动过。

决策不确定性标记：在账本事实之上标出证据缺口，沿依赖边向下游传播，并把未消解的缺口累积为不确定债务。它回答三个问题：证据是否足以支撑结论、缺口在哪里、累计欠了多少。

两项能力互为依据：可审计提供事实，标记在事实之上计算缺口。缺少事实，标记没有挂载对象；缺少标记，事实无法被判断是否足够。

判定与执行策略是接入手段，其作用是决定账本中「依据」一栏写入什么内容，不构成独立能力。

2.2 目标用户与角色

角色	职责	主要诉求
平台管理员	部署、配置策略表、管理权限	控制面可用、变更可追溯
值班与运维人员	监控运行、处理告警	异常动作可拦截、可追溯
开发者	接入 Agent、排查问题	单次运行可回放、字段含义明确
合规与审计人员	核查控制有效性	记录完整、可独立复算
平台运营	管理 Skill 与版本	跨运行表现可比较
采购与法务	评估候选方案	同口径读数可横向对比

2.3 功能范围

1. 对白名单内的 11 类决策执行同步判定，并记录判定结果与证据。
2. 生成、传播三类不确定性标记，并把未消解的标记累积为不确定债务。
3. 以追加写入方式维护账本，支持按运行回放。
4. 每次运行结束产出 8 项读数；按 Skill 维度聚合为 1 项读数。
5. 提供管理能力：发布闸、整改报价、版本对比。

3 目标与指标

3.1 产品目标

编号	目标	验收口径
G1	关键决策全部产出结构化记录	按白名单 11 类计，覆盖率 100%
G2	未覆盖动作显式记录	记为 `UNHOOKED`，不静默通过
G3	三类不确定性标记可生成、可传播	缺证据、源冲突、口径不一致，分 high/mid/low
G4	执行前判定可阻断	规则判定段 P95 低于 50ms；纯规则、无网络、无模型调用
G5	判定故障不默认放行	超时或异常时按决策类处置：高危阻断或转人工，低危放行并记录降级
G6	账本自包含、可复算	删除 OTel 数据后仍可复算 100%

编号	目标	验收口径
G7	运行边界与业务任务一致	resume 不新建运行，仅递增 `segment`
G8	委派可回溯且不污染父级读数	父运行记录委派关系与失败结果；聚合按决策去重，父运行自身决策照常计入
G9	拦截能力可控上线	shadow 期不少于 100 次运行，误报率不高于 5% 后方可开启拦截
G10	不确定性缺口可累积为债务	每条未消解标记计入债务并按等级加权（high 3、mid 2、low 1）；运行结束时债务值与条目数可计算、可列出；补证后对应条目标记为已消解

3.2 成功指标

指标分为四组：过程指标 6 项、单次运行读数 8 项、Skill 聚合读数 1 项、管理指标 3 项。前三组默认产出；管理指标由发布闸与版本对比产出。

组	指标	目标值
过程	关键决策记录完整率	100%
过程	`UNHOOKED` 显式率	100%
过程	Gate P95 延迟	低于 50ms（仅规则判定段，不含 ASK 人工等待）
过程	ASK 人工响应 P95	低于 30 秒
过程	`gate_degraded` 发生率	低于 1%
过程	未覆盖率（跳过 + 未命中白名单）	逐版本登记，超过 5% 即告警
运行读数	声明一致率	不低于 90%
运行读数	证据完整率	不低于 90%
运行读数	复现率	不低于 90%
运行读数	回放一致率	不低于 90%
运行读数	时效有效率	不低于 90%
运行读数	标记密度	逐运行登记，不设达标线；用于跨版本与跨 Skill 比较
运行读数	处置执行率	不低于 95%
运行读数	不确定债务	登记加权缺口总量与未消解条目数，逐版本比较，不设达标线
Skill 聚合	8 项读数按第 6.9 节口径聚合	样本 n ≥ 5 且覆盖 ≥ 3 个决策类时展示
管理	发布闸拦截数	按版本登记，用于对比拦截强度
管理	报价准确率	误差不超过 ±20%
管理	版本间读数差	按版本登记，差值作为比较结果

3.3 非目标

本产品的能力边界如下。

读数衡量证据充分程度，口径由账本字段直接计算。覆盖范围为提供工具调用钩子的框架，以及经适配层接入的框架。语义判断限定在同一语言内。标记来源为账本内数据与策略表声明，模型自评不进入标记。

4 术语与判定口径

4.1 术语

术语	取值	含义	产生方
Gate	`ALLOW` / `ASK` / `DENY` / `REWRITE`	是否放行、是否转人工、是否要求修改参数	Gate 引擎，同步、纯规则
Exec	`normal` / `degrade`	放行后的执行方式	策略表，仅在 `ALLOW` 或 `REWRITE` 后生效
Mark	`high` / `mid` / `low`	不确定性等级	标记引擎
Debt	加权和	未消解标记按等级加权后的累计值，可列出条目、可消解	标记引擎
State	`open` / `closed` / `degraded`	运行的生命周期状态	账本

4.2 判定口径

Gate 输出 `ALLOW`、`ASK`、`DENY`、`REWRITE` 四类结果。`DENY` 表示不执行；`ASK` 表示转人工；`degrade` 仅用于放行后的执行策略，例如将写操作降级为只读。上述口径在接口、界面与对外材料中必须一致，不得混用。

5 使用场景与角色权限

5.1 角色权限

权限模型 v1 冻结，以下矩阵即为实现与验收依据；变更需版本号与留痕。

能力	平台管理员	值班人员	开发者	合规审计	平台运营
查看账本	全部	全部	本人运行	全部只读	所属 Skill
配置策略表	可	不可	不可	不可	不可
切换演示开关	可	限单场景	不可	不可	不可
导出记录	可	可	本人运行	可	可
开启发布闸	可	不可	不可	不可	可

5.2 核心场景

编号	场景	前置条件	主流程	结果
S1	高风险写入拦截	策略表将该类动作配置为 `ASK`	调用前触发 Gate → 转人工 → 人工批准或拒绝	拒绝时动作不执行，记录为 `ASKED` 或 `DENIED`

编号	场景	前置条件	主流程	结果
S2	多 Agent 委派	父 Agent 启动子任务	父运行记录委派；子运行独立开账	父运行记录委派关系与失败结果；聚合按决策去重计数，父运行自身决策照常计入
S3	高风险动作降级	工具已声明只读能力，动作为查询与写入的混合调用	Gate 返回 `ALLOW`，Exec 置为 `degrade`	允许查询，拒绝写入部分
S4	判定故障降级	Gate 超时或异常	高危类阻断或转人工，低危类返回 `ALLOW + gate_degraded`	业务不中断，高风险动作不被放行

5.3 适用行业与扩展条件

本产品不针对特定行业实现，行业差异通过决策白名单与策略表表达。以下行业可按同一架构接入：

行业	典型动作	接入条件
金融投研	取数、生成研报、发送邮件	补充取数与发送类决策；确认数据源可回源
医疗问答	检索指南、生成建议	补充检索类决策；缺证据时强制标记
电商客服	退款、改单、发券	补充资金类决策；配置金额阈值与人工通道
政企数据	跨库查询、批量导出	补充导出类决策；配置数据范围策略
代码 Agent	改文件、执行命令、提交	补充文件与命令类决策；启用 shell 解析

扩展时仅新增决策类与策略条目，不修改账本结构与读数口径。

5.4 使用前提与限制

1. Agent 运行在提供工具调用钩子的框架内，或通过适配层接入；接入时由自检确认钩子生效，结果计入第 10.2 节评测项。
2. 白名单在接入前冻结版本，版本号写入每条决策记录；变更视为口径变更。
3. 账本追加写入、记录不可撤回；接入前完成脱敏规则配置并通过样例校验，未通过不予上线。

6 功能需求

6.1 功能总览

编号	模块	功能说明
F1	决策采集	在每次工具调用前后采集动作信息，生成决策记录；未命中白名单的副作用动作记为 `UNHOOKED`。
F2	证据记录	为每条决策生成自包含证据记录，包含输入摘要、返回摘要、模型与参数、判定结果、时间戳与内容哈希。
F3	不确定性标记	依据账本内数据与策略表声明生成三类标记，按等级标注，沿依赖边传播，并累积为不确定债务。
F4	决策门	执行前依据策略表进行同步判定，输出四类 Gate 结果；超时或异常时按决策类处置，高危阻断，低危降级放行。

编号	模块	功能说明
F5	执行策略	对已放行动作应用 `normal` 或 `degrade` 执行方式，降级仅限制动作范围，不改变判定结果。
F6	账本	以追加写入方式持久化决策与证据，写入前脱敏，每行生成内容哈希，支持按运行检索与导出。
F7	运行生命周期	按业务任务划定运行边界，支持 resume 时递增段号，支持委派关系的父子关联。
F8	读数与聚合	运行结束产出 8 项读数；按 Skill 维度聚合为 1 项读数，样本不足时不展示。
F9	回放	按运行标识重放决策序列，规则判定部分要求结果一致。
F10	管理能力	发布闸、整改报价、版本对比随产品交付，按角色授权开启。

6.2 F1 决策采集

触发条件：Agent 发起工具调用。

处理规则：调用前读取工具名与参数，匹配白名单；命中则创建决策记录并进入 F4；未命中但工具声明为副作用动作（登记字段 `side_effect=true`）则记录为 `UNHOOKED`，不进入判定，并计入未覆盖率。调用完成后追加返回摘要与耗时（见 6.7 两段写）。

输出：决策记录，字段见第 7.2 节。

边界与异常：工具调用被框架跳过时，跳过数量计入未覆盖率，超过阈值触发告警；参数无法脱敏时动作不执行，记为 `DENIED`，原因记为无法脱敏。

6.3 F2 证据记录

触发条件：决策记录创建成功。

处理规则：采集输入快照摘要、工具返回摘要、模型标识与参数、判定结果、时间戳，计算内容哈希后写入。

输出：证据记录，与决策记录一对一关联。

边界与异常：返回内容为空时仍生成记录，标记为空证据；证据体超过存储阈值时仅保留摘要与内容寻址引用。

6.4 F3 不确定性标记

标记	触发条件	判据来源	默认等级
`NO_EVIDENCE`	决策无关联证据或证据为空	账本	命中高危决策类时为 high，其余为 mid
`SOURCE_CONFLICT`	同一断言的两个来源不一致	回源比对，仅对带来源的动作	mid
`SPEC_MISMATCH`	实际参数与策略表声明不一致	策略表与参数摘要	可换算时为 low，否则为 mid

传播规则：仅在"下游引用上游输出"的依赖边上传播；原始等级不因跳数降低，衰减仅作用于下游的「影响呈现」，最低为 low；依赖边缺失时记 `UNKNOWN_DEPENDENCY` 并保持原等级。单次运行的标记密度上限为 100%。

边界与异常：依赖边缺失时记 `UNKNOWN_DEPENDENCY` 并保持原等级，不静默去除；回源不可达时不判定为冲突，记为缺证据。

债务累积：未消解的标记计入债务。权重取等级值：high 记 3，mid 记 2，low 记 1。每条债务条目关联一个决策、一个标记类型、一个权重、一个状态，以及消解时引用的证据。

消解：补证消解 `NO_EVIDENCE`；统一来源消解 `SOURCE_CONFLICT`；修正参数并重新过闸消解 `SPEC_MISMATCH`。消解只追加状态并保留原始条目，原始记录不删除、不改写。

合并：同一运行内按决策标识去重求和。委派场景下父运行汇总子运行的债务并单独列出，聚合时不重复计入。

触发：运行结束时债务值与条目数写入运行读数；单次运行债务值达到策略表阈值时，该运行进入复核队列。

6.5 F4 决策门

处理规则：读取策略表中该决策类的规则，按参数摘要匹配，输出 `ALLOW`、`ASK`、`DENY` 或 `REWRITE`。`REWRITE` 需给出修改后的参数；改写结果必须重新过闸，最多重判 2 轮，仍未通过则 `DENY`，改写后的实参摘要写入 `args_after`。`ASK` 默认等待 30 秒，人工应答后放行或拒绝；超时按策略表的 `ask_timeout_policy` 处置：高危类默认 `DENY + TIMEOUT`，低危类可配置放行。

性能约束：规则判定段 P95 低于 50ms（ASK 人工等待不计入）；不联网、不调用模型、不依赖 OTel 导出。

边界与异常：策略表缺失该类规则时按 `DENY` 处置并记录规则缺失；Gate 异常时按决策类处置，高危阻断、低危放行并标记降级。

6.6 F5 执行策略

处理规则：对 `ALLOW` 与 `REWRITE` 后的动作应用执行方式。`degrade` 仅对白名单中已声明只读能力的工具生效，被限制部分需返回明确原因；工具在登记时声明能力类型（`read_only` / `mixed` / `write`），声明随白名单版本冻结。未声明只读能力的混合调用不得返回 `ALLOW`，应按 `ASK` 或 `DENY` 处置。

边界与异常：降级后仍失败时按普通失败处理，不重复判定。

6.7 F6 账本

账本是一份只能往后写、不能回头改的操作流水，用来回答“当时发生了什么、凭什么放行”。

记什么：每次工具调用分两段写。执行前写一条「意图」记录：属于哪个任务、调用了什么工具、参数摘要、Gate 结果是放行、转人工、拒绝还是改写、判定理由与耗时、本次执行标识。执行后追加一条「结果」记录：输入和输出各留一份摘要、用的是哪个模型和参数、实际执行方式、结束状态、发生时间、这条记录自身的指纹。两条记录共用同一个决策标识，结果通过追加写入产生，不修改意图记录。进程在两段之间崩溃时，重启后扫描超过 60 秒仍无结果的意图记录，标记为 `UNKNOWN_OUTCOME` 并进入复核队列。

怎么保证没被改过：只追加，不修改，不删除。每条记录都带上一条的指纹（内容哈希），首尾串成一条链。改动中间任意一条，其后的记录全部对不上；尾部截断由每日签名检查点（头部哈希与记录长度）检出。

脱敏：账本长期保存，写入前先把手机号、密钥、内部地址等敏感内容替换掉。记录一旦写入就无法撤回，所以脱敏是写入的前提条件，不能留到事后补做。

怎么用：按任务查一次运行的完整过程；按决策类型或时间段批量查；按条件导出给审计或复核方。

出错怎么办：写入失败先重试；重试仍失败就报警，并明确记录“哪条丢了”，不允许静默丢弃。账本不依赖链路日志——链路日志默认只保留 7 天，清理后账本仍能独立读取和复算。

6.8 F7 运行生命周期

规则：一个业务任务对应一个运行；运行标识由任务标识派生，不随进程或对话轮次变化；resume 时递增段号；委派产生的子任务独立开账，父运行仅记录委派关系与失败结果。

输出：运行记录，含状态、起止时间、段号、委派关系。

边界与异常：同一任务重复启动时按任务标识去重；委派深度上限为 3，超限直接 `DENY`。

6.9 F8 读数与聚合

运行读数在运行结束时立即产出，共 8 项：声明一致率、证据完整率、复现率、回放一致率、时效有效率、标记密度、处置执行率、不确定债务。计算口径如下，分母为 0 时该读数记「不适用」，不参与聚合：

读数	分子	分母
声明一致率	实际参数与策略表声明一致的决策数	有声明可比对的决策数
证据完整率	证据记录字段齐全（见 7.2）的决策数	全部决策数
复现率	重放后判定结果一致的决策数	全部决策数（缺证据计为未复现）
回放一致率	规则判定部分回放一致的决策数	规则判定部分的决策数
时效有效率	证据采集时间与动作发生时间偏差不超过 5 秒的决策数	全部决策数
标记密度	带至少一类标记的决策数	全部决策数
处置执行率	按 Gate 结果完成处置的决策数（`DENY` 未执行、`ASK` 已应答并按结果执行均计为已处置）	应处置决策数
不确定债务	未消解标记按等级加权求和（high 3、mid 2、low 1）	不适用（直接登记数值与条目数，无分母）

Skill 读数由运行读数聚合，口径如下：

参数	口径
计数单位	按决策标识去重后计入所属运行；父运行自身的决策计入父运行并参与聚合，仅无自身决策的纯编排运行不计入样本
滚动窗口	最近 20 次有效运行；有效指至少包含 1 个白名单决策
加权方式	等权平均，不按决策类加权
最小样本	样本数不少于 5 且覆盖不少于 3 个决策类
展示方式	只展示读数与样本量，不设 A/B/C/D 分档

样本不足时展示"样本不足"及实际样本数与覆盖类数。

6.10 F9 回放

规则：按运行标识读取决策序列，按原顺序重放。规则判定部分要求结果一致；模型输出部分不要求文本一致，仅比对结构化字段。

边界与异常：证据缺失的决策在回放中标注为不可复现，保留在分母内计为未复现，并单独报告可评估覆盖率。

6.11 F10 管理能力

能力	启用方式	输出
发布闸	默认关闭，开启即生效	通过或阻断，附判定理由
整改报价	默认关闭，开启即生效	按条报价
版本对比	默认关闭，开启即生效	两个版本的读数差

6.12 状态流转

运行状态：`open`（已创建，可写入）→ `closed`（正常结束，只读）。判定降级发生时标记 `degraded`，运行仍可继续写入。

决策事件：`GATE_DECIDED`、`ASK_REQUESTED`、`ASK_ANSWERED`、`EXEC_STARTED`、`EXEC_FINISHED`、`EXEC_FAILED`。事件只追加、不可变更，同一决策标识下按时间排序。

决策状态由事件派生，是只读视图：`ALLOWED`、`ASKED`、`DENIED`、`REWRITTEN`、`UNHOOKED`、`TIMEOUT`、`UNKNOWN_OUTCOME`。结果回填通过追加 `EXEC_FINISHED` 或 `EXEC_FAILED` 事件实现，不修改既有事件。

Gate 结果与决策状态的对应：

Gate 结果	决策状态
ALLOW	ALLOWED
ASK 未应答	ASKED
ASK 拒绝	DENIED
ASK 超时	TIMEOUT（高危类同时不执行）
DENY	DENIED
REWRITE	REWRITTEN
未命中白名单	UNHOOKED
Gate 故障（低危）	ALLOWED，标记 degraded
Gate 故障（高危）	DENIED，标记 degraded

6.13 异常与边界汇总

场景	处理方式
Gate 超时	按决策类处置：高危 DENY + TIMEOUT，低危 ALLOW + TIMEOUT；记录超时原因
Gate 异常	按决策类处置：高危阻断，低危 ALLOW + gate_degraded，计入降级率
证据缺失	生成 NO_EVIDENCE 标记，不阻断
白名单未命中	记 UNHOOKED，动作照常执行但必须记账；计入未覆盖率并告警
账本写入失败	重试后告警，不静默丢弃
参数无法脱敏	动作不执行，记为 DENIED，原因记为无法脱敏

场景	处理方式
委派超深	直接 DENY 并记录
运行重复启动	按任务标识去重

7 数据契约

7.1 契约清单

编号	内容	冻结条件
C1	决策分类枚举，共 11 类	引用白名单 v1.0，修改即口径变更
C2	决策记录与证据记录字段	见 7.2
C3	Gate 判定与超时降级规则	见 6.5
C4	不确定性标记，3 类 3 级	见 6.4
C5	标记传播规则	见 6.4
C6	运行边界与段号规则	见 6.8
C7	账本追加写入、写前脱敏、逐行哈希	见 6.7
C8	断言记录与决策的关联规则	见 7.4
C9	运行读数 8 项与 Skill 聚合 1 项	见 6.9
C10	策略表只读、版本化、变更留痕	见 6.5
C11	决策事件类型与状态派生规则	见 6.12
C12	审批记录字段与 ASK 应答规则	见 7.2、6.5
C13	不确定债务的权重、累积与消解规则	见 6.4

7.2 字段定义

决策记录（意图事件，执行前写入）

字段	类型	必填	说明
decision_id	字符串	是	主键
run_id	字符串	是	所属运行
segment	整数	是	段号，resume 时递增
class	枚举	是	C1 中的决策类；未命中白名单时取 UNCLASSIFIED
tool_name	字符串	是	工具名
args_digest	字符串	是	参数摘要，原文脱敏后存储
args_after	字符串	否	改写后的实参摘要，无改写时为空

字段	类型	必填	说明
whitelist_version	字符串	是	白名单版本号
policy_version	字符串	是	判定所用策略表版本号
rule_snapshot_ref	字符串	是	命中规则快照的内容寻址引用
gate	枚举	是	Gate 结果；未判定时取 NONE
gate_reason	字符串	是	判定理由
gate_latency_ms	整数	是	判定耗时
exec_policy	枚举	是	normal 或 degrade
evidence_ref	字符串	否	证据记录标识，缺失时为空
status	枚举	是	决策状态，由事件派生

证据记录（结果事件，执行后追加）

字段	类型	必填	说明
evidence_id	字符串	是	主键
input_digest	字符串	是	输入快照摘要
output_digest	字符串	是	返回摘要
model_id	字符串	是	模型标识
model_params	字符串	是	模型参数摘要
verdict	字符串	是	判定结果
ts	时间	是	采集时间
content_hash	字符串	是	本行内容哈希

审批记录（仅在 `ASK` 触发时产生）

字段	类型	必填	说明
approval_id	字符串	是	主键
decision_id	字符串	是	关联的决策记录
approver_id	字符串	是	应答人标识
approve_ts	时间	是	应答时间
approved_args_digest	字符串	是	批准时的实参摘要，用于核对是否被替换
approve_result	枚举	是	approve / reject / timeout
content_hash	字符串	是	本行内容哈希

债务记录（标记产生时写入，消解时追加）

字段	类型	必填	说明
debt_id	字符串	是	主键
run_id	字符串	是	所属运行
decision_id	字符串	是	关联的决策记录
mark_type	枚举	是	NO_EVIDENCE / SOURCE_CONFLICT / SPEC_MISMATCH
weight	整数	是	high 3、mid 2、low 1
status	枚举	是	open / resolved
resolve_ref	字符串	否	消解证据引用，未消解时为空
content_hash	字符串	是	本行内容哈希

7.3 传播规则

标记仅在依赖边上传播。原始等级不因跳数降低，下游按「影响呈现」逐跳衰减，最低为 low，不归零。依赖边缺失记 `UNKNOWN_DEPENDENCY` 并保持原等级。单次运行的标记密度上限为 100%，避免全链同时降级而失去区分度。

债务按条目累积：每条未消解标记是一条债务，权重取等级值；同一决策的多类标记分别计条。运行结束时按运行求和并登记。委派场景下父运行汇总子运行债务，聚合时按决策标识去重。消解只追加状态，原始条目的类型与权重保持不变。

7.4 断言记录与决策的关联

断言记录与决策记录分表存储。两者约束不同：决策记录必须包含判定结果与参数摘要，断言记录必须包含定位与来源；合表会导致双方字段大面积空缺且无法分别校验。两者关系为一对多，一次查询可能产出多条断言。

抽取到断言但找不到对应决策时，记录为 `MISSING_DECISION`，状态为「风险未知」：生成 `NO_EVIDENCE` 标记（等级 high），计入声明一致率分母与缺证据统计，并进入复核队列。该情形不得按无风险处理。

8 接入与系统约束

8.1 接入形态

形态	接入点	返回值
进程内 Agent	工具调用前钩子	修改调用参数或跳过调用
外部 Agent	Hook 分发器	ALLOW / DENY / REWRITE / ASK / 提供方策略

两类接入共用同一份策略表。所有工具调用经过统一执行入口，该入口支持跳过执行，判定必须挂在该入口上。

8.2 硬约束

1. Gate 不依赖 OTel 导出器。导出器存在批量、丢弃与不重试行为，不能作为判定依据。
2. OTel 关闭时 Gate 仍可工作。

3. Gate 判定不联网、不调用模型。
4. 账本不依赖 OTel 数据，`trace_ref` 仅为弱引用。

8.3 存储分层

数据	介质	保留策略	是否允许丢失
OTel 链路数据	按天切分的文件	默认 7 天	允许
账本	追加写入数据库	永久	不允许
证据快照	账本内联或内容寻址文件	随账本	不允许

链路引用悬空为允许状态，不影响账本读取与复算。

9 非功能需求

9.1 性能

Gate 判定 P95 延迟低于 50ms（仅规则判定段）；判定过程不得引入网络请求与模型推理。意图记录在工具调用前落盘，结果记录在执行后追加；两段写入的 P95 均不超过 5ms，且不得阻塞工具调用返回；异步队列积压超过 1000 条时告警。

9.2 可靠性

Gate 故障按决策类处置：高危阻断、低危放行并标记；账本写入失败必须告警，不允许静默丢弃；进程重启后账本可继续追加，运行可按标识恢复。

9.3 安全与合规

账本永久保留，写入前必须完成脱敏，覆盖个人信息、凭据与内部地址；脱敏规则随策略表版本化，变更留痕。账本读取按角色隔离，导出行为记入审计记录。记录不得包含可用于重建原始凭据的字段。

9.4 兼容与可运维

锁定 openJiuwen 0.1.20.post1；框架升级需重跑第 10.2 节评测项。策略表为只读配置，支持版本号与变更记录，回滚通过切换版本完成。

10 验收标准

10.1 功能验收

编号	验收项	通过标准
A1	白名单覆盖	11 类决策均能生成记录，覆盖率 100%
A2	未覆盖动作	副作用动作未命中白名单时记为 `UNHOOKED`

编号	验收项	通过标准
A3	判定可控	配置为 ASK 的动作经人工应答后执行；超时按策略表处置，高危类一律不执行，低危类可按配置放行；配置为 DENY 的动作不执行
A4	降级执行	degrade 生效时仅允许受限操作，越界操作返回明确原因
A5	账本自包含	删除 OTel 数据后，账本仍可读取并复算
A6	读数产出	运行结束即产出 8 项读数；样本不足时显示样本提示
A7	回放	规则判定部分回放一致率不低于 90%
A8	债务结算	每条未消解标记计入债务条目；运行结束时债务值与条目数可计算、可列出；补证后对应条目标记为已消解，原始记录保留

10.2 评测项

项	方法	通过线
账本自包含	构造 3 次运行，删除 OTel 数据后复算	100% 可复算
钩子覆盖	列举 10 个写操作实测	受控入口覆盖 10/10；未经入口的必须被识别并计入 UNHOOKED，静默通过即判不通过
运行边界	3 轮对话加 2 次 resume	运行标识不变，段号递增
两段写恢复	在意图记录与结果记录之间注入进程崩溃	意图记录 60 秒内被标记 UNKNOWN_OUTCOME，无静默丢失
shadow 误报	不少于 100 次运行统计，人工复核标注真值	误报率不高于 5% 方可开启拦截；误报指复核判定为不应阻断的拦截
回放一致	规则判定部分重放	不低于 90%
红队样本	10 个样本	不低于 8 个被阻断或转人工
债务结算	构造缺证据、源冲突、参数不一致三类标记各 2 条，其中 3 条补证消解	债务值等于未消解标记加权和；条目数、消解引用可逐条列出；消解后原始条目仍可读

11 风险与缓解

风险	影响	缓解措施
钩子语义缺口，如命令内部写、子进程写、外部工具内部写	覆盖率虚高，分母不可信	用命令解析拆分判定；无法判定的一律按 ASK 转人工，不设排除项
框架按轮次生成会话标识	resume 被切成多段	运行标识绑定业务任务，轮次标识仅作段号
Gate 同步故障	Agent 全链路阻塞	超时与异常按决策类处置：高危阻断，低危放行并计入降级率
OTel 默认保留 7 天	链路引用悬空	账本自包含，引用仅作弱关联
个人信息进入账本且不可撤回	合规风险	写前脱敏作为写入前置条件
循环委派	账本无限增长	委派深度上限 3，按任务去重

风险	影响	缓解措施
框架版本漂移	接口变更导致判定失效	锁定版本，升级须重跑评测项

委派规则：责任链可回溯，但不回滚上级读数；深度上限 3，超限直接拒绝；聚合按决策去重计数，父运行自身的决策照常计入。